

Uniwersytet Warszawski

Wydział Filozofii

Kamil Tomaszek

Nr albumu: 432044

Minimalizacja długości zależności
w strukturach współrzędnie złożonych:
badanie korpusowe na podstawie
Polish Dependency Bank

Praca licencjacka

na kierunku KOGNITYWISTYKA

Praca wykonana pod kierunkiem

prof. dr hab. Adama Przepiórkowskiego

Uniwersytet Warszawski

Warszawa, czerwiec 2023

Streszczenie

Praca licencjacka na temat "Minimalizacja długości zależności w strukturach współrzędnie złożonych: badanie korpusowe na podstawie Polish Dependency Bank" jest poświęcona zjawisku minimalizacji długości zależności (DLM) w koordynacji w języku polskim. Celem pracy jest sprawdzenie hipotez na ten temat oraz przedstawienie dodatkowych analiz. Ma ona charakter empiryczny i opiera się na danych pochodzących z Polish Dependency Bank (PDB). Praca składa się z sześciu rozdziałów. W pierwszym rozdziale przedstawiłem motywację, cel i zakres pracy oraz jej strukturę. W drugim rozdziale omówiłem teoretyczne podstawy pracy, tj. reprezentacje koordynacji w języku polskim, teorię zależności składniowej i DLM w koordynacji. W trzecim rozdziale opisałem źródło danych i narzędzia do analizy, tj. PDB i preprocessing danych za pomocą algorytmu napisanego w Pythonie. W czwartym rozdziale zaprezentowałem wyniki analizy statystycznej wykonanej w R oraz testowanie hipotez za pomocą m. in. testu chi-kwadrat. W piątym rozdziale dokonałem dyskusji wyników, interpretacji ich znaczenia i porównania z literaturą naukową. W szóstym rozdziale podsumowałem pracę i wnioski oraz zaproponowałem perspektywy dalszych badań.

Słowa kluczowe

koordynacja, minimalizacja długości zależności, Polish Dependency Bank, drzewo zależnościowe, korpus języka polskiego

Tytuł pracy w języku angielskim

Dependency Length Minimisation in coordinate structures: A corpus study based on Polish Dependency Bank

Spis treści

1. Wstęp	4
1.1. Motywacja i cel pracy	4
1.2. Zakres i struktura pracy	5
2. Teoretyczne podstawy minimalizacji długości zależności w strukturach współrzędnie złożonych	6
2.1. Koordynacja w języku polskim	6
2.2. Zarys teorii zależności składniowej	7
2.3. Minimalizacja długości zależności	7
2.4. Różne reprezentacje koordynacji	9
3. Polish Dependency Bank – źródło danych i narzędzia do analizy	10
3.1. Krótki opis Polish Dependency Bank	10
3.2. Preprocessing danych	10
3.3. Dane po preprocessingu	10
4. Analiza statystyczna	11
4.1. Hipoteza, metody	11
4.2. Przedstawienie wyników analizy statystycznej w R	11
4.3. Testowanie hipotez	11
5. Dyskusja wyników	12
5.1. Podsumowanie wyników badań	12
5.2. Interpretacja wyników	12
5.3. Przegląd literatury	12
6. Zakończenie	13
6.1. Podsumowanie pracy i wnioski	13
6.2. Perspektywy dalszych badań	13
Bibliografia	14
Załączniki	15

Rozdział 1

Wstęp

W tym rozdziale przedstawiam motywację i cel pracy licencjackiej na temat "Minimalizacja długości zależności w strukturach współrzędnie złożonych: badanie korpusowe na podstawie Polish Dependency Bank", a także omawiam jej zakres oraz strukturę.

1.1. Motywacja i cel pracy

Praca ta ma na celu analizę zjawiska minimalizacji długości zależności – DLM (z ang. Dependency Length Minimisation), czyli tendencji do umieszczania elementów współrzędnych o różnych długościach w sposób, by zmniejszyć odległość zarówno między nimi samymi, jak i między nimi a innymi elementami zdania, w koordynacjach w języku polskim. Koordynacja to zjawisko, gdy wiele części zdania ma jeden nadrzędnik i każda z nich się z nim koordynuje. Zjawisko to jest istotne dla teorii składniowej i reprezentacji językowych, ponieważ dotyczy zarówno formy jak i znaczenia zdań. W pracy tej sprawdzono dwie hipotezy dotyczące długości członów w koordynacjach w języku polskim: 1. że dłuższy człon koordynacji jest częściej ze strony prawej i 2. że dłuższy człon koordynacji jest częściej dalej od jej nadrzędnika.

(0) *Widziałem Asię i jej śmiesznego, młodszego brata.*

Długości członów mierzono na cztery różne sposoby, licząc znaki, sylaby, słowa oraz tokeny. W przykładzie (0) odpowiednie wartości wynosiłyby [4 vs 31, 2 vs 9, 1 vs 4, 1 vs 5]. Szybko pokazano, że jedna z hipotez zachodzi w większości przypadków, więc następnie omówiono wpływ obecności i pozycji nadrzędnika oraz długości różnicy między analizowanymi członami na proporcje danych, w których hipoteza ta jest prawdziwa. Praca ta ma charakter empiryczny, opiera się na danych pochodzących z Polish Dependency Bank (PDB), czyli korpusu języka polskiego zawierającego ponad 22 tysiące drzew zależnościowych oraz na podobnej pracy badającej te same zależności, ale dla języka angielskiego (Anonimowe Zgłoszenie na ACL, nieopublikowane).

1.2. Zakres i struktura pracy

Praca składa się z sześciu rozdziałów. W rozdziale drugim omówiono teoretyczne podstawy pracy, tj. przedstawiono czym są koordynacje – na przykładzie języka polskiego, zaprezentowano zarys teorii zależności składniowej, opisano minimalizację teorii zależności oraz wskazano różne reprezentacje zależnościowe wraz z ich przewidywaniami. W rozdziale trzecim opisano źródło danych, czyli Polish Dependency Bank, jak i ich preprocessing – działanie algorytmu, napisanego w języku Python, wybierającego koordynacje oraz informacje o nich z PDB, a także pokazano format danych po preprocessingu w pliku z rozszerzeniem ".csv". W rozdziale czwartym zaprezentowano hipotezy badawcze, ich testowanie wraz z analizami statystycznymi w języku R (m. in. test Wilcoxa, testy chi-kwadrat oraz ogólne modele liniowe [GLM – z ang. Generalised Linear Models]). W rozdziale piątym omówiono wyniki badań i ich interpretację w kontekście istniejącej wcześniej literatury naukowej. W rozdziale szóstym podsumowano pracę, wyciągnięto z niej wnioski oraz zaproponowano perspektywy dalszych badań.

Rozdział 2

Teoretyczne podstawy minimalizacji długości zależności w strukturach współrzędnie złożonych

W tym rozdziale omawiam teoretyczne podstawy pracy, tj. reprezentacje koordynacji w języku polskim, teorię zależności składniowej i DLM w koordynacji.

2.1. Koordynacja w języku polskim

Zacznę od przedstawienia pojęcia koordynacji. Koordynacja to zjawisko w językach naturalnych, które zachodzi w strukturach złożonych – zarówno współrzędnie, jak i podrzędnie. Polega na zestawieniu dwóch lub więcej elementów o tej samej funkcji składniowej za pomocą spójników lub interpunkcji i tym samym złączenie ich w jeden, większy element, zachowujący te same funkcje składniowe. Jest ono jednym z podstawowych sposobów łączenia słów, czy zdań. Elementami koordynacji mogą być zarówno pojedyncze słowa (1a, 1b), wyrażenia (1c), jak i całe zdania (1d):

(1)

- a. Ania **i** Julia *idą* na spacer.
- b. Ania **i** Julia.
- c. Wesoła Marysia **oraz** smutny Janek *wybrali się* do parku.
- d. Kuba zjadł obiad **a** następnie poszedł spać.

Człony koordynacji nazywamy koordynantami, to co je łączy – spójnikiem koordynacji (w przykładach w tej pracy jest on ilustrowany pogrubionym tekstem), a wyraz nadrzędny względem obu członów – głową koordynacji (w przykładach ilustrowany kursywą). Jak widać w (1b) nie zawsze istnieje głowa koordynacji. W podanych wyżej przykładach koordynantami są: (1a, 1b) Ania, Julia; (1c) Wesoła Marysia, smutny

Janek; (1d) zjadł obiad, poszedł spać.

Ze względów semantycznych zwykle wyróżnia się cztery rodzaje koordynacji: koordynacje koniunkcyjne (2a), koordynacje dysjunkcyjne (2b), koordynacje adversatywne (2c) oraz koordynacje kauzalne (2d) (Haspelmath, 2007). Każde z nich używają różnych zestawów spójników, które łączą koordynanty. W koordynacjach koniunkcyjnych koordynanty łączą m. in. spójniki [i, oraz, ani, tudzież, również], a w koordynacjach dysjunkcyjnych – [albo, bądź, lub, czy], lecz w obu tych kategoriach wykorzystywana jest także interpunkcja. W koordynacjach adversatywnych używamy m. in. spójników [ale, lecz, zaś, natomiast, jednak], a w koordynacjach kauzalnych – [bo, ponieważ, dlatego że]. W tej pracy skupię się na pierwszych trzech rodzajach koordynacji, jako że to one występują w strukturach współrzędnie złożonych.

(2)

- a. Marta *zjadła* jabłko **i** gruszkę.
- b. Ona miała szesnaście **lub** siedemnaście *lat*.
- c. *Byli* ładni, **ale** głupi.
- d. Nie zrobiłem pracy domowej, **bo** nie chciałem.

2.2. Zarys teorii zależności składniowej

Tekst sekcji

2.3. Minimalizacja długości zależności

Minimalizacja długości zależności (DLM) to zasada, według której języki naturalne dążą do zmniejszania odległości między słowami zależnymi syntaktycznie. Zasada ta jest odnotowywana w lingwistyce już od długiego czasu i pozwala nam na bardziej efektywne analizowanie i generowanie języka naturalnego. W ciągu ostatnich 20 lat hipoteza o nacisku na DLM została wykorzystana do wyjaśnienia wielu z najbardziej uniwersalnych właściwości języków (Futrell et al., 2015). Jak twierdzą Hawkins (1994) i Futrell et al. (2020), rozróżniamy jej występowanie na poziom gramatyczny, jak i codzienne użycie języka.

Według DLM, jeśli oba ustawienia członów koordynacji binarnych (jeden człon raz z lewej strony, raz z prawej) są gramatycznie poprawne, to bliżej głowy znajdzie się krótszy człon. W przykładach (3a, 3b) oba ustawienia wydają się brzmieć naturalnie, jednak gdy wydłużymy jeden z członów – w (3c, 3d), zauważymy, że bardziej naturalne będzie ustawienie krótszego członu z lewej strony.

(3)

- a. *Nie ma* Kamila **i** Julii.
- b. *Nie ma* Julii **i** Kamila.
- c. *Nie ma* Kamila **i** wiecznie spóźnionej Julii.
- d. *Nie ma* wiecznie spóźnionej Julii **i** Kamila.

Hawkins (1994) argumentuje, że DLM występuje w gramatyce, ale niekoniecznie w użyciu codziennym. Jako powód wskazuje, że w języku angielskim kolejność V-NP-PP (V - czasownik [z ang. verb], NP - fraza rzeczownikowa [z ang. nominal phrase], PP - fraza przyimkowa [z ang. prepositional phrase]) występuje częściej niż V-PP-NP nie tylko gdy NP jest krótsze od PP, ale i wtedy gdy są podobnej długości. Używa on tego przykładu, ponieważ jest on jednym z tych, które uważa się za ilustrujące występowanie DLM (jako że NP są zazwyczaj krótsze niż PP). Słowa Hawkinsa dla języka angielskiego ilustrują przykłady (4a, 4b), w których kolejność V-NP-PP jest bardziej naturalna niż V-PP-NP), mimo że obie frazy są podobnej długości. Zdanie (4c) również brzmi jednak naturalnie, co wskazuje na pewien wpływ dodatkowego czynnika – długości różnicy obu członów koordynacji na to, czy DLM będzie w danym przypadku zachowana.

(4)

- a. I gave <a book> <to John>. [Dałem <książkę> <Johnowi>.]
- b. I gave <to John> <a book>. [Dałem <Johnowi> <książkę>.]
- c. I gave <to John> <the most interesting book I've read in years>. [Dałem <Johnowi> <najbardziej interesującą książkę, jaką przeczytałem od lat>.]

Za: Anonimowe Zgłoszenie na ACL (nieopublikowane)

Jednym ze sposobów na badanie DLM jest tworzenie sztucznych języków losowych (w których kolejność słów, czy relacje zależności są losowo dobierane) oraz porównywanie długości zależności w tych językach z długościami zależności w językach naturalnych. Badania takie wykazały, że języki naturalne mają znacznie krótsze długości zależności niż języki losowe, co sugeruje, że istnieje uniwersalna tendencja u ludzi do wykorzystywania DLM (Liu, 2008; Ferrer-i-Cancho & Liu, 2014).

DLM jest również powiązana z innymi właściwościami języków naturalnych, takimi jak projektywność i finalność głowy. Projektywność oznacza brak lub rzadkość przecinających się zależności, które wydłużają długość zależności. Finalność głowy oznacza kierunek występowania nadrzędnika frazy względem jej dopełnienia. Badania wykazały, że istnieje związek między finalnością głowy a długością zależności, przy czym języki o finalności głowy na końcu zdania mają krótszą długość zależności niż języki o finalności głowy na początku zdania (Futrell et al., 2015).

DLM nie jest jednak jedynym czynnikiem kształtującym strukturę syntaktyczną ję-

zyków naturalnych. Istnieją również inne ograniczenia i preferencje, takie jak harmonia głowy, ograniczenia informacyjne czy preferencje semantyczne, które mogą wpływać na kolejność słów i długość zależności. Niektóre z tych czynników mogą być sprzeczne lub komplementarne względem DLM. Dlatego DLM należy rozumieć jako jeden z wielu czynników wpływających na organizację języka naturalnego (Temperley, 2018).

2.4. Różne reprezentacje koordynacji

Tekst sekcji

Rozdział 3

Polish Dependency Bank – źródło danych i narzędzia do analizy

Tekst rozdziału

3.1. Krótki opis Polish Dependency Bank

Tekst sekcji

3.2. Preprocessing danych

Tekst sekcji

3.3. Dane po preprocessingu

Tekst sekcji

Rozdział 4

Analiza statystyczna

Tekst rozdziału

4.1. Hipoteza, metody

Tekst sekcji

4.2. Przedstawienie wyników analizy statystycznej w R

Tekst sekcji

4.3. Testowanie hipotez

Tekst sekcji

Rozdział 5

Dyskusja wyników

Tekst rozdziału

5.1. Podsumowanie wyników badań

Tekst sekcji

5.2. Interpretacja wyników

Tekst sekcji

5.3. Przegląd literatury

Tekst sekcji

Rozdział 6

Zakończenie

Tekst rozdziału

6.1. Podsumowanie pracy i wnioski

Tekst sekcji

6.2. Perspektywy dalszych badań

Tekst sekcji

Bibliografia

- Anonimowe Zgłoszenie na ACL 2023 (nieopublikowane). Conjunct Lengths in English, Dependency Length Minimization, and Dependency Structure of Coordination
- Ferrer-i-Cancho, R., Liu, H. (2014). The risks of mixing dependency lengths from sequences of different length. *Glottology* 5(2), 143-155. <https://doi.org/10.48550/arXiv.1304.3841>
- Futrell, R., Mahowald, K., & Gibson, E. (2015). Large-scale evidence of dependency length minimization in 37 languages. *Proceedings of the National Academy of Sciences* 112(33), 10336–10341. <https://doi.org/10.1073/pnas.1502134112>
- Futrell, R., Levy R. P., & Gibson, E. (2020). Dependency locality as an explanatory principle for word order. *Language* 96(2), 371–412. Za: Anonimowe Zgłoszenie na ACL 2023 (nieopublikowane). Conjunct Lengths in English, Dependency Length Minimization, and Dependency Structure of Coordination
- Haspelmath, M. (2007). Coordination. In T. Shopen (Ed.), *Language typology and syntactic description, Volume II: Complex constructions* (pp. 1-51). Cambridge University Press.
- Hawkins, J. A. (1994). A Performance Theory of Order and Constituency. *Cambridge University Press*. Za: Anonimowe Zgłoszenie na ACL 2023 (nieopublikowane). Conjunct Lengths in English, Dependency Length Minimization, and Dependency Structure of Coordination
- Liu, H. (2008). Dependency distance as a metric of language comprehension difficulty. *Journal of Cognitive Science* 9(2), 159–191. <https://doi.org/10.17791/jcs.2008.9.2.159>
- Shuang, K., Tan, Y., Cai, Z., & Sun, Y. (2020). Natural language modeling with syntactic structure dependency. *Information Sciences* 523, 220-233. <https://doi.org/10.1016/j.ins.2020.03.031>
- Temperley, D. (2018). Minimizing dependency length in phrasal and sentential coordination: A quantitative study of English and German. *Journal of Quantitative Linguistics* 25(3), 223–244. <https://doi.org/10.1080/09296174.2017.1390669>

Załączniki